

**МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ
КОММУНИКАЦИЙ РОССИЙСКОЙ ФЕДЕРАЦИИ**

Ордена Трудового Красного Знамени федеральное государственное
бюджетное образовательное учреждение
высшего образования

«Московский технический университет связи и информатики»
(МТУСИ)

ОТЧЕТ

по учебной технологической (проектно-технологической) практике
(вид и тип практики)

студента Петрищева Е.С.

группы МТИ2532

Москва
2026

Для выполнения работы был выбран датасет Numenta Anomaly Benchmark (NAB).

Источник: Kaggle (<https://www.kaggle.com/datasets/boltzmannbrain/nab>)

Конкретный файл: realTweets.csv

Предметная область: Мониторинг социальных сетей.

Структура данных: Временной ряд, состоящий из двух столбцов: timestamp (временная метка) и value (количество упоминаний/твитов в минуту).

Смысл показателя: Количество твитов, содержащих определенное ключевое слово.

Аномалии: Резкий всплеск активности (например, вирусный пост или начало важного события), который выбивается из обычного фонового уровня.

Цель анализа: Разработать прототип, который может прогнозировать фоновый уровень трафика и автоматически сигнализировать о нештатных всплесках.

В выбранном датасете следующие показатели исходного ряда:




Рисунок 1. Исходные показатели

Простая базовая модель прогнозирования (Random Forest)

Обучаем простой Random Forest (базовый уровень относительно других моделей)

```
rf_model = RandomForestRegressor(n_estimators=100, random_state=42, n_jobs=-1)
```




Рисунок 2. Прогноз RandomForest.

В ходе работы были обучены также две другие модели: XGBOOST, которая продемонстрировала следующие метрики:

1. MAE: 45.1469
2. MSE: 88665.3672
3. RMSE: 297.7673

И Gradient Boosting:

1. MAE: 40.0898
2. RMSE: 239.6545
3. MSE: 57434.2706

В результате обучения и последующего предсказания, лучшей моделью оказалась Gradient Boosting по всем трём метрикам:

MAE = 40.09 — средняя ошибка прогноза (на 8.9% лучше Random Forest)

RMSE = 239.65 — среднеквадратичная ошибка (на 0.9% лучше Random Forest)

MSE = 57434.27 — квадрат ошибки (на 1.7% лучше Random Forest)

Gradient Boosting:

Последовательное обучение — каждое новое дерево исправляет ошибки предыдущих, что позволяет лучше улавливать сложные зависимости в данных.

Устойчивость к выбросам — Gradient Boosting оказался менее чувствительным к резким всплескам, чем XGBoost.

Оптимальная глубина деревьев — параметры модели (`max_depth=3`, `learning_rate=0.1`) оказались хорошо сбалансированными для данного набора данных.

Random Forest — это усреднение независимых деревьев, что даёт стабильный, но не всегда оптимальный результат. Он проще в настройке, но уступает бустингу в точности на сложных данных.

XGBoost более чувствителен к выбору гиперпараметров (`learning_rate`, `max_depth`, `regularization`). На этих данных модель, вероятно, переобучилась на шум, что привело к увеличению RMSE (297.77).

Практический вывод

Для прогнозирования волатильных временных рядов с резкими скачками лучше всего подходит Gradient Boosting. Он даёт минимальную ошибку и показывает стабильные результаты.

Вывод: в реальных проектах использовать Gradient Boosting или LightGBM (после дополнительной настройки гиперпараметров).

Вторая часть работы была посвящена обнаружению аномалий во временном ряду. Были реализованы два метода:

1. Статистический Z-Score (простейший метод)
2. Isolation Forest (метод машинного обучения)




Рисунок 3. Z-score





Рисунок 4. Isolation Forest

Оценка результатов обнаружения аномалий

В датасете NAB есть разметка аномалий, но она находится в отдельном CSV файле. Для учебных целей мы создадим искусственную "метку" (label), принимая за эталон результат Z-Score, так как это общепринятый метод, или используем встроенный файл. Чтобы показать полноценный анализ Precision/Recall, необходимо загрузить файл с разметкой

Сравнение методов обнаружения аномалий:

	Метод	Precision	Recall	F1-Score
0	Z-Score	1.000000	0.006241	0.012405
1	Isolation Forest	0.962264	0.048228	0.091853



****Вывод:**** Isolation Forest показывает более высокий F1-score, что говорит о его лучшей способности находить аномалии.

Рисунок 5. Confusion matrix

Интерпретация результатов и выводы

Прогнозирование:

Базовая модель Random Forest (100 деревьев, 10 лаговых признаков) показала среднюю абсолютную ошибку $MAE = 44.00$, что составляет $\sim 18\%$ от среднего значения ряда (245). Это приемлемый результат для волатильных данных, но модель сглаживает пиковые значения.

XGBoost с аналогичными гиперпараметрами ($n_estimators=100$, $max_depth=5$) показала $MAE = 45.15$ — результат хуже Random Forest. Вероятная причина: XGBoost более чувствителен к выбросам и переобучается на шумовых всплесках в данных.

Gradient Boosting ($n_estimators=100$, $learning_rate=0.1$, $max_depth=3$) показал лучший результат $MAE = 40.09$, что на 8.9% лучше Random Forest. Последовательное обучение деревьев позволяет модели последовательно исправлять ошибки предыдущих деревьев, эффективнее улавливая нелинейные зависимости и адаптируясь к резким изменениям ряда.

ARIMA (проверены параметры (5,1,0), (2,1,0), (5,0,0)) не подошла для данных: во всех случаях прогноз представлял собой константу, равную среднему значению обучающей выборки (~ 245). Это связано с тем, что ARIMA — линейная модель, а ряд содержит нелинейные всплески до 2000 единиц, которые модель не может учесть.